

CASO PRÁCTICO: ANÁLISIS DE SUPERVIVENCIA Y DATOS DEMOGRÁFICOS DEL TITANIC

Objetivo: Aplicar técnicas de importación de datos, manipulación de estructuras básicas (listas), operaciones vectorizadas con NumPy y análisis exploratorio con Pandas DataFrame.

Preparación previa: Abre tu entorno de Python (Jupyter Notebook, Google Colab, etc.) e importa las librerías necesarias (pandas, numpy, math). Asegúrate de tener el archivo titanic.csv en tu directorio de trabajo.

Módulo 1: Lectura de Archivos (CSV y Excel)

- **Actividad 1: Leer un archivo CSV.** Utiliza Pandas para cargar el archivo adjunto titanic.csv en un DataFrame llamado df_titanic.
- **Actividad 2: Exportar y Leer un archivo Excel.** Para practicar la lectura de Excel, primero exporta una muestra del DataFrame a un archivo .xlsx y luego vuélvelo a leer creando un nuevo DataFrame llamado df_excel.

Módulo 2: Uso de Listas Clásicas en Python

- **Actividad 3: Creación manual de listas.** Crea una lista en Python llamada columnas_clave que contenga en formato de texto los nombres de las variables más importantes: 'Survived', 'Pclass', 'Sex', 'Age' y 'Fare'.
- **Actividad 4: Iteración básica sobre una lista.** Recorre la lista columnas_clave con un bucle for e imprime cada nombre de columna en mayúsculas.

Módulo 3: Listas en Analítica de Datos (Python)

- **Actividad 5: Extraer datos de Pandas a una lista.** Extrae los valores de la columna 'Fare' (Tarifa) de los primeros 20 pasajeros y conviértelos en una lista nativa de Python llamada lista_tarifas.
- **Actividad 6: List Comprehensions (Listas de comprensión) para limpieza.** La lista generada podría tener valores muy altos o decimales complejos. Usa una *list comprehension* para crear una nueva lista llamada tarifas_redondeadas que contenga las tarifas redondeadas a un número entero.

Módulo 4: NumPy en Analítica de Datos

- **Actividad 7: Convertir listas a Arrays de NumPy.** Toma la lista_tarifas y conviértela en un arreglo (array) de NumPy llamado array_tarifas.

- **Actividad 8: Matemáticas vectorizadas con NumPy.** Supongamos que queremos aplicar un impuesto del 15% a todas las tarifas del array. Usa operaciones vectorizadas de NumPy para multiplicar todo el array por 1.15 sin usar bucles.
- **Actividad 9: Funciones estadísticas de NumPy.** Utiliza las funciones nativas de NumPy para calcular el valor máximo, mínimo y la desviación estándar del array_tarifas.
- **Actividad 10: Lógica condicional con np.where.** Crea un nuevo array de NumPy a partir de las edades completas del DataFrame (ignorando nulos). Usa np.where para clasificar como "Mayor de edad" a los ≥ 18 y "Menor de edad" a los < 18 .

Módulo 5: Pandas DataFrame (Análisis Exploratorio y Limpieza)

- **Actividad 11: Inspección inicial del DataFrame.** Muestra las primeras 8 filas y las últimas 5 filas del DataFrame df_titanic para entender la estructura de los datos.
- **Actividad 12: Información técnica del dataset.** Utiliza un método de Pandas para visualizar los tipos de datos de cada columna y la cantidad de valores No Nulos (para detectar valores faltantes).
- **Actividad 13: Estadísticas descriptivas.** Genera un resumen estadístico (media, percentiles, min, max) únicamente de las columnas numéricas del DataFrame.
- **Actividad 14: Conteo de frecuencias (Variables Categóricas).** Calcula cuántos hombres y mujeres había en el barco utilizando la columna 'Sex'.
- **Actividad 15: Filtrado de datos (Slicing).** Crea un nuevo DataFrame llamado df_sobrevivientes que contenga exclusivamente a los pasajeros que sobrevivieron (Survived == 1).
- **Actividad 16: Filtrado con múltiples condiciones.** Filtra el DataFrame para encontrar a las mujeres ('female') que viajaban en primera clase ('Pclass' == 1).
- **Actividad 17: Tratamiento de valores nulos (Imputación).** La columna 'Age' tiene valores nulos. Rellena esos espacios vacíos (NaN) utilizando la **mediana** de las edades de todos los pasajeros.
- **Actividad 18: Eliminación de columnas innecesarias.** La columna 'Cabin' tiene demasiados valores nulos y 'Ticket' no aporta valor numérico inmediato. Elimina ambas columnas del DataFrame de forma permanente.
- **Actividad 19: Creación de nuevas columnas (Ingeniería de características).** Crea una nueva columna llamada Tamaño_Familia que sea el resultado de sumar la cantidad de hermanos/cónyuges ('SibSp'), padres/hijos ('Parch') y sumarle 1 (el propio pasajero).

- **Actividad 20: Agrupación de datos (Groupby).** Agrupa los datos por 'Pclass' (Clase del pasajero) y calcula el promedio de la tarifa ('Fare') y el promedio de supervivencia ('Survived') para evaluar cómo la clase afectó el precio y las posibilidades de vivir.

Producto para entregar:

Archivo resuelto de ipynb

Vigencia:

28/05/2026 hasta las 23:59 horas

Ing. Juan Carlos Arbelaez